# Trabalho Integrado de Fundamentos de IA

Do Simbólico à Incerteza

Adrya Vieira, Hagata Rodrigues, Luís Abdalla,
Maria Penha, Miguel Bezerra, Rafaelly Dos Anjos

## 1 Introdução e dados

A pergunta que orienta o trabalho é: um auto de infração do IBAMA por desmatamento terá multa de valor elevado? Os dados vêm dos autos de infração do IBAMA em 2021 (Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis, 2021) e dos dados históricos das estações automáticas do INMET, também de 2021 (Instituto Nacional de Meteorologia, 2021). Nome e CPF ou CNPJ de quem foi multado não foram usados nem guardados.

Do arquivo original ficaram só os autos de desmatamento, sem os cancelados ou excluídos e com multa simples (sem advertência). A Tabela 1 mostra quantos autos sobram em cada passo.

| Passo | Autos |
|---|---|
| Todos os autos do arquivo | 9663 |
| Infrações de Flora | 4142 |
| Marcados como desmatamento | 2780 |
| Sem autos cancelados ou excluídos | 2641 |
| Somente multa simples | 2639 |
| Com valor de multa maior que zero | 2639 |

Tabela 1: Seleção dos autos de infração.

A variável-alvo `Multa_Alta` vale 1 quando o valor da multa passa da mediana, R$ 100.000,00: são 1326 autos de multa baixa (50,2%) e 1313 de multa alta (49,8%).

Os seis atributos são fáceis de explicar. Três vêm do IBAMA: o bioma (`BIOMA`), o tipo de pessoa autuada (`TP_PESSOA_INFRATOR`) e o tipo de ação de fiscalização (`TIPO_ACAO`). Três vêm do INMET: chuva, temperatura e umidade, em três faixas do mesmo tamanho (`CHUVA_FAIXA`, `TEMP_FAIXA` e `UMID_FAIXA`). Cada auto recebe o clima da sua unidade da federação e do seu mês, com a média das estações (estações com menos de cerca de 15 dias de medição no mês foram descartadas). Autos sem clima ficaram em `sem_dado` (178 na chuva e 100 na temperatura e na umidade), e 21 autos estão sem bioma.

## 2 Etapa 1 – Árvore de decisão

### 2.1 Entropia e ganho de informação

A entropia de um conjunto $S$ é $H(S) = -\sum_c p_c \log_2 p_c$, e o ganho de um atributo $A$ é $G(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v)$. Na raiz há 2639 autos (1326 de multa baixa e 1313 de multa alta), então $H(S) = 1{,}0000$. Dividindo pelo bioma, os subgrupos são Amazônia (1600 autos, $H = 0{,}9091$), Mata Atlântica (410, 0,7219), Caatinga (278, 0,3731), Cerrado (277, 0,9599), Pantanal (36, 0,9911), Pampa (11, 0) e Costeiro e Marinho

(6, 0). Os 21 autos sem bioma não entram em nenhum subgrupo. Assim,

$$G(S, \text{BIOMA}) = 1{,}0000 - \Big[\tfrac{1600}{2639}(0{,}9091) + \tfrac{410}{2639}(0{,}7219) + \tfrac{278}{2639}(0{,}3731) + \tfrac{277}{2639}(0{,}9599) + \tfrac{36}{2639}(0{,}9911)\Big] \approx 0{,}1831.$$

A Tabela 2 mostra os ganhos dos três primeiros níveis, seguindo o ramo da Amazônia e, dentro dele, o das pessoas físicas. Nos outros ramos do segundo nível, o atributo escolhido foi `CHUVA_FAIXA` na Caatinga (ganho 0,0054), `TIPO_ACAO` no Cerrado (0,0435), `UMID_FAIXA` na Mata Atlântica (0,0399) e `CHUVA_FAIXA` no Pantanal (0,3879, de um grupo de só 36 autos). Pampa e Costeiro e Marinho já são folhas de multa baixa.

| Grupo (autos; entropia) | Atributo | Ganho |
|---|---|---|
| Todos (2639; 1,0000) | `BIOMA` | **0,1831** |
| | `TEMP_FAIXA` | 0,0440 |
| | `UMID_FAIXA` | 0,0392 |
| | `CHUVA_FAIXA` | 0,0288 |
| | `TP_PESSOA_INFRATOR` | 0,0256 |
| | `TIPO_ACAO` | 0,0008 |
| Amazônia (1600; 0,9091) | `TP_PESSOA_INFRATOR` | **0,0223** |
| | `TEMP_FAIXA` | 0,0220 |
| | `UMID_FAIXA` | 0,0161 |
| | `CHUVA_FAIXA` | 0,0102 |
| | `TIPO_ACAO` | 0,0034 |
| Amazônia, pessoa física (1460; 0,8788) | `TEMP_FAIXA` | **0,0206** |
| | `UMID_FAIXA` | 0,0202 |
| | `CHUVA_FAIXA` | 0,0078 |
| | `TIPO_ACAO` | 0,0015 |

Tabela 2: Ganho de informação nos três primeiros níveis. Em negrito, o atributo escolhido.

## 2.2 Árvore do zero, scikit-learn e validação cruzada

A árvore foi feita do zero, de forma recursiva: se todos os autos do grupo têm a mesma classe, vira folha; se não sobram atributos ou a profundidade máxima foi atingida, vira folha com a classe mais comum; caso contrário, escolhe o atributo de maior ganho e cria um ramo por valor. Ela foi comparada com a do scikit-learn (critério de entropia, dois ramos por divisão). Com 80% dos autos para treino e 20% para teste e profundidade 4, a árvore própria teve acurácia de 0,757 no treino e 0,752 no teste, e a do scikit-learn teve 0,750 no teste. Sem limite de profundidade, a árvore própria foi para 0,772 no treino e caiu para 0,735 no teste (sobreajuste). O enunciado espera de 85 a 92% no treino sem poda; não chegamos lá porque os seis atributos têm poucas categorias, e muitos autos com os mesmos valores têm multas de classes diferentes.

Na validação cruzada de 5 partes (semente 42, Tabela 3), a árvore própria teve a melhor acurácia média na profundidade 4 (74,0%), e a do scikit-learn ficou perto de 73,6% nas profundidades 3 e 5. O bioma é o atributo mais importante: a Amazônia tem 1081 de 1600 autos de multa alta (67,6%), contra 38,3% no Cerrado, 20,0% na Mata Atlântica e 7,2% na Caatinga. O tipo de ação quase não ajuda (ganho de 0,0008).

| Profundidade | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|
| Árvore própria | 0,714 | 0,723 | 0,731 | **0,740** | 0,735 | 0,732 |
| scikit-learn | 0,715 | 0,726 | 0,736 | 0,734 | 0,736 | 0,735 |

Tabela 3: Acurácia média na validação cruzada de 5 partes.

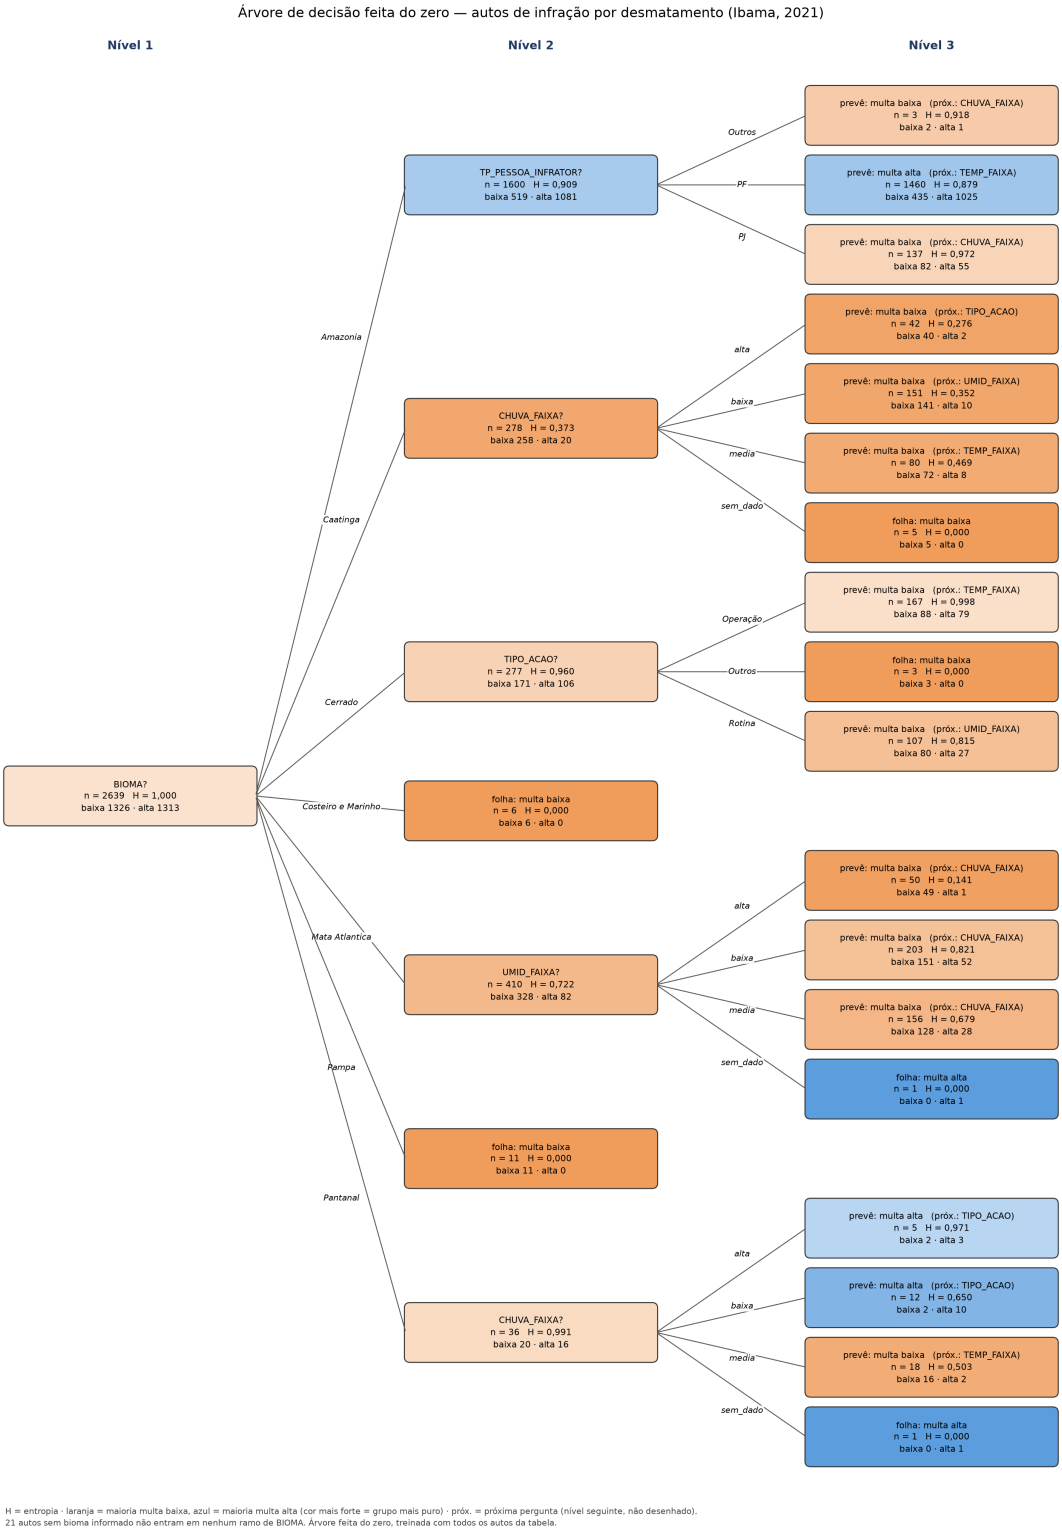



Figura 1: Três primeiros níveis da árvore feita do zero. $H$ é a entropia; laranja é maioria de multa baixa, azul de multa alta.

### 2.3 Limitações da lógica: monotonicidade

Na lógica clássica, se uma conclusão foi provada a partir de um conjunto de fatos, acrescentar novos fatos nunca derruba essa conclusão. Isso se chama monotonicidade. Se $KB \models \alpha$, então $KB \cup \{\beta\} \models \alpha$ para qualquer $\beta$. O aprendizado a partir de dados não funciona assim: a regra é tirada de exemplos, e um exemplo novo pode contradizê-la.

O exemplo clássico são os cisnes. Uma árvore aprendida com quatro cisnes brancos (Europa, Europa, América e Ásia) prevê que um cisne da Oceania é branco. Ao acrescentar um único cisne preto da Oceania, a árvore é refeita e a previsão passa a ser preto. A conclusão anterior foi retirada, e na lógica clássica isso não pode acontecer.

O mesmo ocorre com os autos do IBAMA. Na árvore da Figura 1, o ramo Pampa tem 11 autos, todos de multa baixa (entropia 0), e a regra aprendida é "auto no Pampa tem multa baixa". Se chegasse um único auto do Pampa com multa alta, o grupo passaria a ter 12 autos, com entropia $-\frac{11}{12}\log_2\frac{11}{12} - \frac{1}{12}\log_2\frac{1}{12} =$ 0,414. O ramo deixaria de ser folha e a árvore precisaria escolher outro atributo para separar os dois casos. O mesmo vale para o Costeiro e Marinho, com 6 autos de multa baixa. Regras com poucos autos são frágeis: na Mata Atlântica, o ramo de umidade "sem dado" tem um único auto, de multa alta, e a árvore passa a prever multa alta para esse caso, embora 80% dos autos do bioma tenham multa baixa.

A conclusão é que uma árvore de decisão guarda uma hipótese que vale para os dados vistos até agora. Ela é revisável, e por isso mais próxima do raciocínio com incerteza que da dedução. Isso motiva as Etapas 3 a 6, em que a crença em uma conclusão é um número que muda quando chegam novas evidências.

## 3 Etapa 2 – Aprendizado linear

O alvo contínuo é $\log(1 + \text{valor da multa})$, porque os valores vão de poucos reais a milhões. Os atributos são chuva, temperatura e umidade do mês, bioma, tipo de pessoa, tipo de ação e UF (a UF não estava na árvore da Etapa 1; entrou porque melhora a regressão). A separação é 80% treino e 20% teste (semente 42), com faltantes preenchidos por valores do treino. Para a regressão, ficaram de fora os autos de valor zero e o 1% de maiores multas (limite de R$ 10.059.080,00, calculado no treino), porque multas de dezenas de milhões dominavam o $R^2$ de poucos autos do teste; sobraram 2089 autos de treino e 523 de teste.

A regressão simples usou a fórmula fechada com o atributo mais correlacionado com o alvo (`UF_PA`). A múltipla foi feita pela fórmula fechada e por gradiente descendente do zero, com os mesmos pesos e o mesmo $R^2$ do scikit-learn. No Ridge, o $\lambda$ (= 24,2) foi escolhido por validação cruzada de 5 partes no treino, sem usar o teste (Figura 2). A regressão logística foi feita do zero (sigmoide e gradiente) para a pergunta da Etapa 1, com todos os autos: acertou 77,08% no teste, igual ao scikit-learn, contra 50,19% de quem sempre prevê a classe mais comum. Sem a UF, a acurácia cai para 71,97% e o $R^2$ da múltipla para 0,25.

| Modelo | Esperado | Do zero | scikit-learn |
|---|---|---|---|
| Regressão linear simples ($R^2$) | 0,55–0,65 | 0,044 | 0,044 |
| Múltipla, fórmula fechada ($R^2$) | 0,70–0,80 | 0,392 | 0,392 |
| Múltipla, gradiente descendente ($R^2$) | 0,70–0,80 | 0,392 | – |
| Ridge, $\lambda$ ótimo ($R^2$) | 0,72–0,82 | 0,392 | 0,392 |
| Regressão logística (acurácia) | 78–85% | 77,08% | 77,08% |

Tabela 4: Resultados da Etapa 2 no teste e faixa esperada no enunciado.

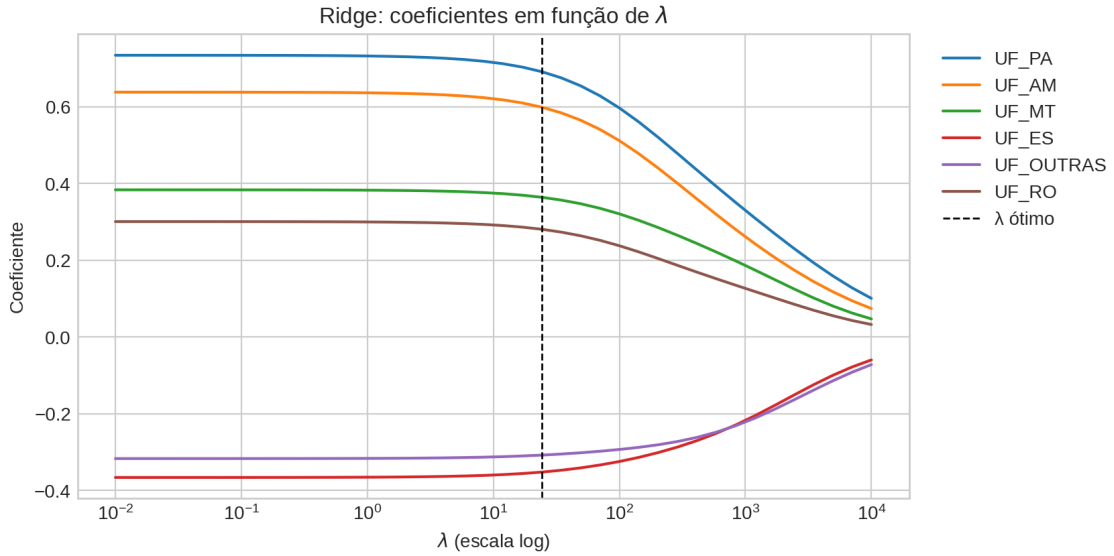



Figura 2: Coeficientes do Ridge em função de $\lambda$ (os seis maiores). A linha tracejada marca o $\lambda$ escolhido.

O $R^2$ e a acurácia ficaram abaixo da faixa esperada, mas não por erro de implementação: a fórmula fechada, o gradiente descendente e o scikit-learn chegam ao mesmo resultado. O valor de uma multa por desmatamento depende sobretudo da área desmatada, e a tabela não traz essa coluna. O clima do INMET é um valor por estado e mês, repetido em muitos autos, e explica pouco. O Ridge não ajudou porque, com 2089 autos e poucos atributos, não há sobreajuste a corrigir.

## 4 Etapa 3 – Probabilidade

A Etapa 3 descreve com probabilidades os 1847 autos de treino (70% dos 2639, separação estratificada, semente 42). A análise é só descritiva: não prova independência na população nem causa e efeito. Foram escolhidas duas variáveis binárias: $A$, que vale 1 para o bioma Amazônia, e $B$, que vale 1 para pessoa jurídica. A Tabela 5 mostra a distribuição conjunta, com os quatro eventos atômicos (soma 1).

| | $B=0$ (outros) | $B=1$ (pessoa jurídica) |
|---|---|---|
| $A=0$ (outros biomas) | 0,3124 | 0,0661 |
| $A=1$ (Amazônia) | 0,5679 | 0,0536 |

Tabela 5: Distribuição conjunta $P(A, B)$ no treino.

As marginais saem da soma da tabela: $P(A{=}1) = 0{,}6215$ e $P(B{=}1) = 0{,}1197$. A condicional é $P(A \mid B) = P(A, B)/P(B)$; por exemplo, $P(A{=}1 \mid B{=}1) = 0{,}0536/0{,}1197 \approx 0{,}4480$. A regra da cadeia, $P(A, B, C) = P(A)\,P(B \mid A)\,P(C \mid A, B)$, com $C$ igual a multa alta, deu 0,02003 para $A = B = C = 1$, o mesmo valor da contagem direta. Pelo Teorema de Bayes, $P(C \mid A) = P(A \mid C)\,P(C)/P(A)$: entre os autos de multa alta, 84,0% são da Amazônia, e entre os da Amazônia, 67,3% têm multa alta (0,6725, igual à contagem direta). $P(\text{multa alta} \mid \text{Amazônia})$ segue uma direção de causa plausível, e $P(\text{Amazônia} \mid \text{multa alta})$ é uma leitura de diagnóstico.

Para a independência condicional, $A$ e $B$ são independentes dada a classe $C$ se $P(A, B \mid C) = P(A \mid C)\,P(B \mid C)$. Na classe multa baixa, o lado esquerdo deu 0,0668 e o direito 0,0742; na classe multa alta, 0,0403 e 0,0466. A diferença é pequena (menos de um ponto percentual), mas a igualdade não vale, e não foi feito teste estatístico. Assim, a suposição do Naive Bayes é só uma aproximação nos nossos dados.

A lógica de primeira ordem lida com afirmações verdadeiras ou falsas, como "todo auto da Amazônia tem multa alta". Nos dados essa regra é falsa (só 67,3% têm multa alta), e a lógica não consegue dizer "67% de chance"; a probabilidade guarda esse número.

# 5 Etapa 4 – Aprendizado probabilístico e EM

As Etapas 3 e 4 usam a mesma tabela e o mesmo rótulo da Etapa 1: 1847 autos de treino e 792 de teste externo (30%, separação estratificada, semente 42). Autos do mesmo processo podem cair no treino e no teste, então as acurácias podem ficar um pouco otimistas.

## 5.1 MLE, MAP e Naive Bayes

Para um parâmetro de Bernoulli com $k$ sucessos em $n$ tentativas, a MLE é $\hat{\theta} = k/n$, e a MAP com prior Beta$(2, 2)$ é $\hat{\theta} = (k + 1)/(n + 2)$, que puxa o valor para perto de 0,5 quando há poucos dados. Entre os 919 autos de multa alta do treino, 772 são da Amazônia: a MLE de $P(\text{Amazônia} \mid \text{multa alta})$ é $772/919 = 0{,}8400$ e a MAP é $773/921 = 0{,}8393$ (com tantos dados, quase iguais).

O Naive Bayes foi feito do zero, com $P(y \mid x) \propto P(y) \prod_j P(x_j \mid y)$ e os seis atributos da Etapa 1 transformados em 26 colunas de 0 e 1. A probabilidade de cada coluna dada a classe usa a MAP acima, e a de cada classe usa suavização de Laplace. Na validação cruzada de 5 partes, só no treino, a acurácia foi 72,50% ± 0,94%, contra 50,24% de quem sempre responde a classe mais comum. No teste externo foram 71,84% de acurácia, 70,31% de precisão, 75,13% de recall e 72,64% de F1, perto dos 74,0% da árvore da Etapa 1.

## 5.2 Variável oculta e algoritmo EM

A variável oculta $Z$ representa o tipo de clima do mês e do estado. Ela não está nos dados e é inferida de chuva, temperatura média e umidade média (padronizadas com a média e o desvio do treino), modeladas por uma mistura de $K$ gaussianas. O passo E calcula a responsabilidade $r_{ik} = \theta_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k) / \sum_j \theta_j \mathcal{N}(x_i \mid \mu_j, \Sigma_j)$, e o passo M atualiza $\theta_k = N_k/N$, $\mu_k = \sum_i r_{ik} x_i / N_k$ e $\Sigma_k$, com $N_k = \sum_i r_{ik}$. O algoritmo foi feito do zero (`em.py`), com contas em logaritmo e $10^{-6}$ somado à diagonal da covariância. Ele para quando a log-verossimilhança média melhora menos que $10^{-6}$ (no máximo 200 iterações), com 5 inicializações aleatórias e semente 42.

Num teste com dois grupos sintéticos conhecidos (médias $[0, 0]$ e $[5, 4]$, pesos 0,6 e 0,4), o EM achou médias [0,05; 0,01] e [5,01; 3,97] e pesos 0,6 e 0,4, em 92 iterações. Nos dados reais, com $K = 2$, convergiu em 25 iterações, e a log-verossimilhança só subiu (Figura 3). O $Z_0$ reúne meses chuvosos, quentes e úmidos, e o $Z_1$, meses secos e mais amenos (Tabela 6). Entre os autos de treino, 93,2% têm clima completo; os demais ficam com $Z =$ `sem_dado`.

| Grupo | Peso | Chuva (mm) | Temperatura (°C) | Umidade (%) |
|---|---|---|---|---|
| $Z_0$ | 0,582 | 192,2 | 26,2 | 79,1 |
| $Z_1$ | 0,418 | 51,7 | 24,2 | 64,0 |

Tabela 6: Médias dos dois grupos de clima encontrados pelo EM ($K = 2$).

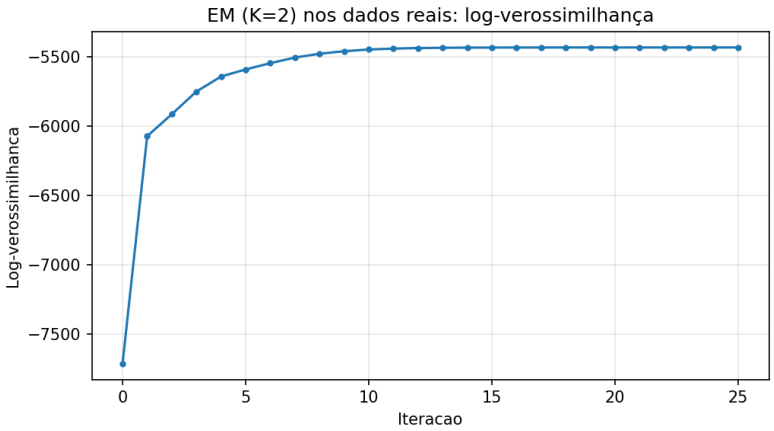



Figura 3: Log-verossimilhança do EM ($K = 2$) por iteração, nos dados reais.

### 5.3 Naive Bayes puro e com $Z$

O $Z$ entrou como atributo do Naive Bayes, com o EM ajustado só no treino de cada parte da validação cruzada (Tabela 7). Ele não melhorou o modelo: a queda na validação cruzada foi de 2,4 a 3,7 pontos percentuais, maior que o desvio entre as partes, e no teste externo o modelo com $Z$ errou 17 a 32 autos a mais, em 792. O enunciado espera de 80 a 86% com EM, e isso não aconteceu. Trocar as faixas de clima pelo $Z$ também não ajudou.

| Configuração | Validação cruzada (5 partes) | Teste externo |
|---|---|---|
| Naive Bayes puro | 72,50% ± 0,94% | 71,84% |
| Naive Bayes + $Z$ ($K = 2$) | 68,76% ± 2,53% | 69,19% |
| Naive Bayes + $Z$ ($K = 3$) | 69,36% ± 1,51% | 69,70% |
| $Z$ ($K = 2$) no lugar das faixas de clima | 70,06% ± 1,95% | 67,80% |

Tabela 7: Acurácia do Naive Bayes sem e com a variável oculta $Z$.

O que aprendemos é que uma variável oculta só ajuda se trouxer informação nova sobre o alvo. O EM funcionou como algoritmo, mas o $Z$ é feito só de clima, e o clima pouco ajuda a prever a multa (na Etapa 1, o ganho de informação de chuva, temperatura e umidade é de 0,03 a 0,04, contra 0,18 do bioma). Além disso, o EM maximiza a verossimilhança do clima e não olha para o alvo, e o $Z$ é um resumo mais pobre que as faixas, que o Naive Bayes já recebia.

## 6 Etapa 5 – Redes Bayesianas

A rede usa cinco variáveis (`CHUVA_FAIXA`, `TEMP_FAIXA`, `BIOMA`, `TIPO_ACAO` e `Multa_Alta`) e cinco arestas, justificadas na Tabela 8. As justificativas são hipóteses do grupo, não provas. A aresta do bioma para a multa foi acrescentada depois de uma primeira versão em que a única causa da multa era o tipo de ação; nela, a probabilidade de multa alta só tinha três valores (entre 0,488 e 0,522). Como `Multa_Alta` só tem `BIOMA` e `TIPO_ACAO` como pais, chuva e temperatura não mudam a probabilidade que sai da rede.

| Aresta | Justificativa |
|---|---|
| CHUVA_FAIXA → TIPO_ACAO | o clima pode mudar quando a equipe consegue ir a campo |
| TEMP_FAIXA → TIPO_ACAO | idem |
| BIOMA → TIPO_ACAO | o tipo de ação pode mudar de uma região para outra |
| TIPO_ACAO → Multa_Alta | uma operação planejada pode achar infrações maiores |
| BIOMA → Multa_Alta | o bioma tem relação forte com a multa (Amazônia: 67,6% altas) |

Tabela 8: Arestas da rede bayesiana.

As tabelas de probabilidade condicional foram estimadas com o `BayesianEstimator` do pgmpy, com suavização BDeu (tamanho amostral equivalente 10), em 2618 autos (os 21 sem bioma ficaram fora do ajuste). A inferência foi feita por enumeração, do zero (multiplica as tabelas, soma sobre as variáveis ocultas e normaliza), e com a eliminação de variáveis do pgmpy; as duas deram o mesmo resultado nas três consultas testadas (Tabela 9).

| Evidência | Enumeração | pgmpy |
|---|---|---|
| TIPO_ACAO = Operação | 0,5058 | 0,5058 |
| BIOMA = Amazônia e TIPO_ACAO = Rotina | 0,6418 | 0,6418 |
| BIOMA = Caatinga | 0,0756 | 0,0756 |

Tabela 9: Probabilidade de multa alta dada a evidência.

Duas independências foram verificadas por d-separação. A primeira é um colisor: CHUVA_FAIXA e BIOMA são pais de TIPO_ACAO; sem evidência o caminho está fechado (independentes), e ao observar TIPO_ACAO ele abre (dependentes). A segunda é uma cadeia: TEMP_FAIXA e Multa_Alta são dependentes, mas ficam independentes quando TIPO_ACAO e BIOMA são conhecidos. A conjunta completa das cinco variáveis precisaria de 671 parâmetros e a rede precisa de 257, uma economia de 414. Para cada um dos 2639 autos foi calculada a probabilidade de multa alta dada a evidência do próprio auto (de 0,028 a 0,947, com 26 valores diferentes), e o resultado foi salvo para a Etapa 6.

# 7 Etapa 6 – Lógica fuzzy

Esta etapa constrói um sistema fuzzy do tipo Mamdani, proposto a partir da lógica fuzzy de Zadeh (1965), que permite graus de pertinência entre 0 e 1 e se adapta à imprecisão da linguagem natural (HÜLLERMEIER, 2011). Ele foi feito com a biblioteca `scikit-fuzzy` (`fuzzy.py`) e transforma duas informações do domínio em uma prioridade de atuação.

## 7.1 Variáveis, pertinências e regras

O sistema tem duas entradas e uma saída. **risco** (0 a 1) é a probabilidade de multa alta da rede da Etapa 5. **efeito** (0 a 3) vem da coluna EFEITO_MEIO_AMBIENTE do IBAMA (Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis, 2021), convertida em Desprezível = 0, Fraca = 1, Moderada = 2 e Significativa = 3 (81, 657, 528 e 613 autos). Os 760 restantes (559 "Potencial" e 201 vazios) ficaram fora da escala. **prioridade** (0 a 100) é a saída. Todas usam funções triangulares $[a, b, c]$ com três conjuntos que se sobrepõem (Tabela 10 e Figura 4). Os conjuntos de risco foram ajustados à distribuição das probabilidades da rede, que ficam em três grupos (perto de 0,1 a 0,2, de 0,4 e entre 0,65 e 0,7): numa primeira versão, com "médio" em [0,2; 0,5; 0,8] e "alto" em [0,6; 1; 1], quase nenhum auto chegava a prioridade alta.

| Variável | Baixo / fraco / baixa | Médio / média | Alto / forte / alta |
|---|---|---|---|
| risco | [0, 0, 0,4] | [0,2, 0,45, 0,7] | [0,5, 1, 1] |
| efeito | [0, 0, 1,5] | [0,5, 1,5, 2,5] | [1,5, 3, 3] |
| prioridade | [0, 0, 50] | [25, 50, 75] | [50, 100, 100] |

Tabela 10: Parâmetros $[a, b, c]$ das funções de pertinência triangulares.

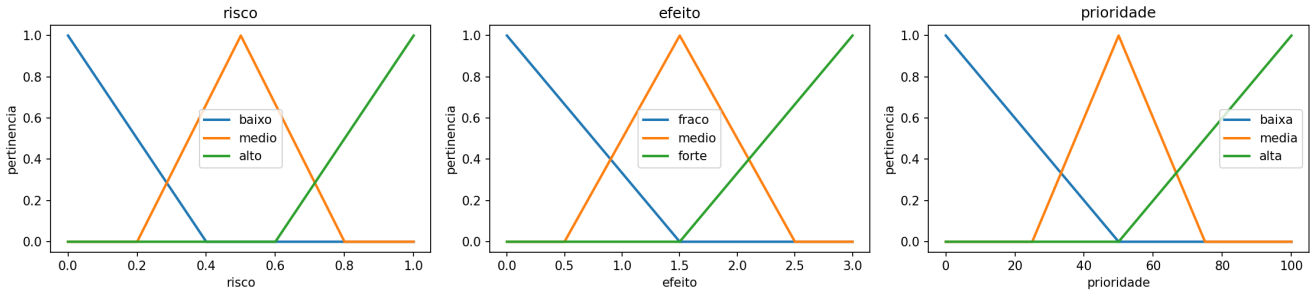



Figura 4: Funções de pertinência de risco, efeito e prioridade.

O sistema usa cinco regras, com E (mínimo) e OU (máximo), que cobrem todas as combinações das entradas; a saída vira número pelo centroide, e por isso a prioridade nunca chega exatamente a 0 ou a 100.

| | Regra |
|---|---|
| R1 | Se risco é alto E (efeito é médio OU forte), então prioridade é alta. |
| R2 | Se risco é alto E efeito é fraco, então prioridade é média. |
| R3 | Se risco é médio, então prioridade é média. |
| R4 | Se risco é baixo E efeito é forte, então prioridade é média. |
| R5 | Se risco é baixo E (efeito é fraco OU médio), então prioridade é baixa. |

Tabela 11: Base de regras do sistema fuzzy.

Para ver se o sistema responde de forma coerente, ele foi testado com valores digitados à mão, e não com resultados de algum modelo (Tabela 12). A prioridade aumenta conforme o risco e o efeito aumentam.

| risco | efeito | prioridade (fuzzy) |
|---|---|---|
| 0,10 | 0 | 17,5 |
| 0,45 | 1 | 50,0 |
| 0,55 | 2 | 54,1 |
| 0,80 | 3 | 81,4 |
| 0,95 | 3 | 83,2 |

Tabela 12: Testes com valores digitados à mão. Não são resultados da Rede Bayesiana.

A Figura 5 mostra a superfície de resposta do sistema. A prioridade é mais baixa (em torno de 17) quando risco e efeito são baixos e mais alta (cerca de 83) quando ambos são altos. Para risco perto de 0,45, a prioridade fica em torno de 50, qualquer que seja o efeito, o que corresponde à regra R3.

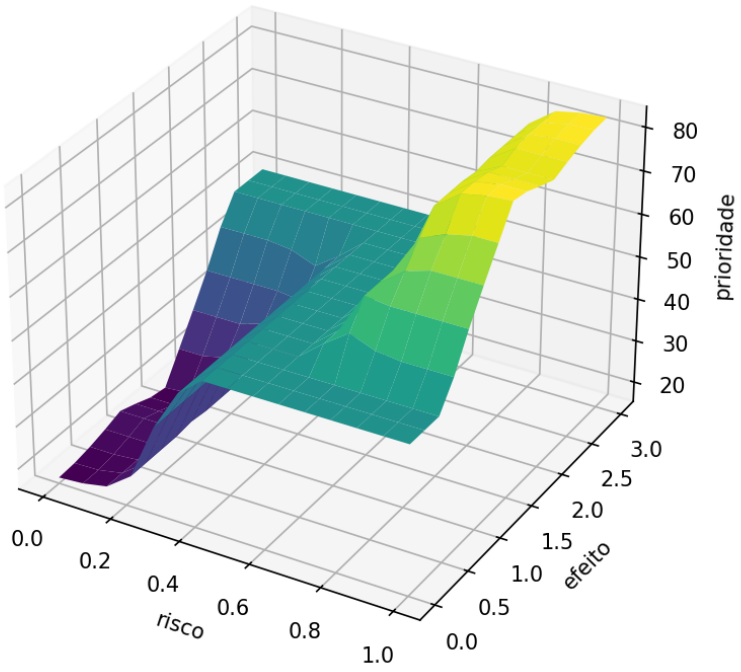



Figura 5: Superfície de resposta: prioridade em função do risco e do efeito.

### 7.2 Alimentação pela rede e comparação com a decisão rígida

O sistema foi alimentado com as probabilidades da Etapa 5 (de 0,028 a 0,947; 706 autos até 0,2, 126 entre 0,2 e 0,4, 201 entre 0,4 e 0,6, 1600 entre 0,6 e 0,8 e 6 acima de 0,8). Como ele precisa do efeito, a comparação usou os 1879 autos que o têm. Os 760 sem efeito têm menos multas altas (40,7%) do que os 1879 usados (53,4%), então não são uma amostra aleatória. A decisão rígida chama de multa alta todo auto com risco de 0,5 ou mais; a prioridade do fuzzy foi dividida em baixa (menos de 33), média (33 a 66) e alta (66 ou mais).

| Decisão rígida | fuzzy baixa | fuzzy média | fuzzy alta |
|---|---|---|---|
| BAIXA (risco menor que 0,5) | 462 | 267 | 0 |
| ALTA (risco de 0,5 ou mais) | 0 | 611 | 539 |

Tabela 13: Decisão rígida e rótulo do fuzzy nos 1879 autos com efeito.

O fuzzy tem uma faixa do meio que a decisão rígida não tem: 878 dos 1879 autos (46,7%) ficaram como prioridade média. Dos 1150 autos de decisão ALTA, 539 (46,9%) também são alta no fuzzy e 611 (53,1%) ficam no meio; nenhum auto de risco menor que 0,5 virou prioridade alta, e nenhum de risco 0,5 ou mais virou baixa. A prioridade média dos autos que de fato tiveram multa alta foi 66,6, contra 44,5 dos de multa baixa. Nos 132 autos de fronteira (risco entre 0,4 e 0,6), onde uma pequena mudança no risco inverte a decisão rígida, a prioridade ficou em 50,0 na maioria dos casos (máximo 57,1), qualquer que fosse o efeito: a decisão rígida os joga para lados opostos, e o fuzzy trata todos como prioridade média. O fuzzy usa também o efeito, os cortes de 33 e 66 foram escolhidos por nós, e a rede foi treinada com os mesmos autos comparados, então a comparação só descreve como as duas decisões se comportam, não mede qual acerta mais.

Quanto à interpretabilidade, cada regra pode ser lida por alguém da área sem cálculo: a R1 diz que,

com risco alto e efeito médio ou forte, a prioridade é alta, e dá para dizer qual regra foi mais ativada. O custo é que regras e limites foram escolhidos por nós, e a R3 não olha o efeito, então para risco médio a prioridade fica perto de 50 mesmo com efeito forte.

# 8 Pipeline integrado e conclusões

Todas as etapas partem da mesma tabela (`tabela_p4.csv`, 2639 autos), do mesmo rótulo `Multa_Alta` e da semente 42 (Figura 6). As setas tracejadas mostram o que uma etapa deixou para outra: a Etapa 1 mostrou que o bioma é o atributo mais informativo (ganho de 0,18), e por isso a rede tem a aresta do bioma para a multa; e a estimação com suavização da Etapa 4 (MAP e Laplace) reaparece nas tabelas da rede (BDeu). A única ligação por arquivo é da Etapa 5 para a Etapa 6: a probabilidade de multa alta de cada auto entra no fuzzy como `risco`, junto com o efeito, e sai a prioridade de atuação.

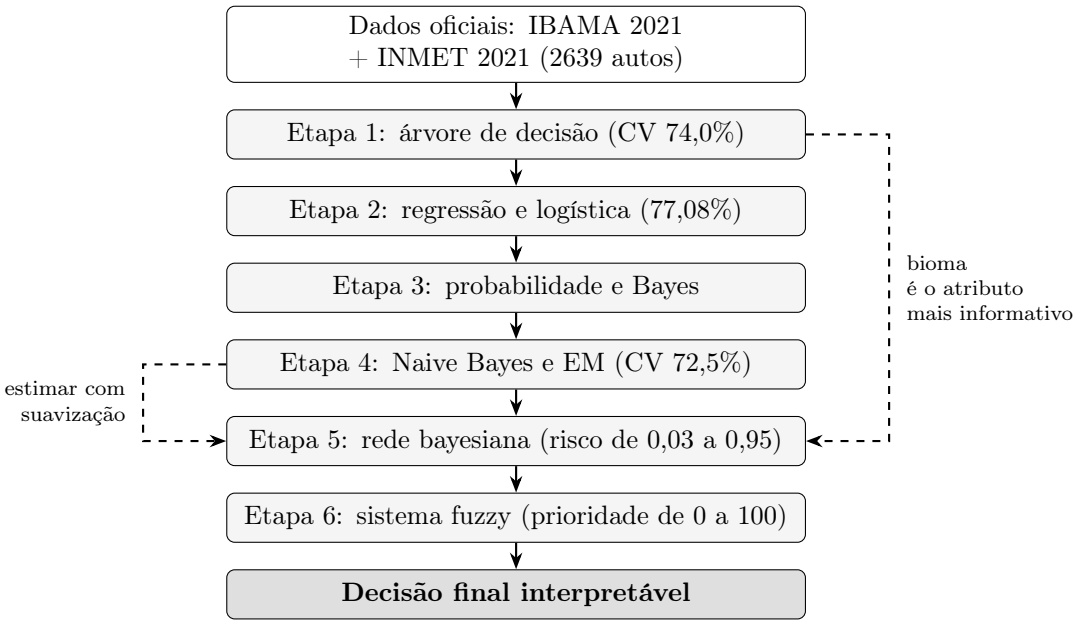



Figura 6: Pipeline do trabalho. As setas tracejadas indicam o que as Etapas 1 e 4 deixaram para a Etapa 5.

Na classificação de `Multa_Alta`, a árvore (Etapa 1) obteve 74,0% de acurácia, o Naive Bayes (Etapa 4) 72,5% e a regressão logística (Etapa 2) 77,08% (71,97% sem a UF, que os outros dois não usaram), e o $R^2$ máximo foi 0,392. Em todos os casos o bioma foi o atributo mais importante. Vários resultados ficaram abaixo das faixas do enunciado (regressão, logística e Naive Bayes com EM), e a explicação mais provável está nos dados: o valor da multa depende da área desmatada, que não está na tabela. A Etapa 1 mostrou, com o exemplo do Pampa, que uma regra aprendida pode ser derrubada por um único exemplo novo, o que justifica passar a modelos com probabilidades; e a Etapa 4 mostrou que uma variável oculta só ajuda se trouxer informação nova sobre o alvo.

Na Etapa 6, o fuzzy recebeu o risco da rede e o efeito no meio ambiente. Ao contrário da decisão rígida (corte em 0,5), ele colocou os autos de fronteira em prioridade média e entrega uma recomendação que um especialista consegue ler e auditar regra por regra, embora isso não prove que acerte mais. Como melhorias, ficam a extração da área desmatada a partir do texto do auto e o uso de dados de clima com maior detalhe regional do que a média mensal por estado.

## Referências

HÜLLERMEIER, E. Fuzzy machine learning and data mining. *WIREs Data Mining and Knowledge Discovery*, v. 1, n. 4, p. 269–283, 2011.

Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis. *Autos de Infração*. 2021. Dados abertos. Disponível em: <https://dadosabertos.ibama.gov.br>. Acesso em: 29 out. 2026.

Instituto Nacional de Meteorologia. *Dados Históricos Anuais: Estações Automáticas*. 2021. Portal do INMET. Disponível em: <https://portal.inmet.gov.br/dadoshistoricos>. Acesso em: 1 nov. 2026.

RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4. ed. [S.l.]: Pearson, 2020.

ZADEH, L. A. Fuzzy sets. *Information and Control*, v. 8, n. 3, p. 338–353, 1965.

## A Prompts utilizados com chatbot

Conforme exigência do trabalho, esta seção documenta a rastreabilidade da interação com a Inteligência Artificial durante o desenvolvimento de cada etapa.

### Etapa 1 – Árvore de decisão (Rafaelly Dos Anjos)

- **Pedido original:** "Como faço a árvore de decisão do zero no Python usando entropia e ganho de informação?"
  **Resposta resumida:** Apresentou a lógica recursiva para calcular a entropia e o ganho em cada nó, ajudando na implementação manual da indução de regras.

- **Pedido original:** "Como explico a monotonicidade da lógica clássica pro relatório usando o exemplo empírico do bioma Pampa?"
  **Resposta resumida:** Ajudou a redigir a análise teórica, relacionando a fragilidade das regras da lógica clássica com os dados reais encontrados no bioma Pampa.

### Etapa 2 – Aprendizado linear (Miguel Bezerra)

- **Pedido original:** "Como implemento a regressão linear múltipla por gradiente descendente do zero com regularização Ridge?"
  **Resposta resumida:** Gerou a estrutura base iterativa e o código para aplicar a regularização Ridge usando validação cruzada para o lambda.

- **Pedido original:** "O $R^2$ das minhas regressões ficou em 0,392. Como justifico no texto que a limitação é a ausência da área desmatada nos dados?"
  **Resposta resumida:** Forneceu argumentos técnicos defendendo que a métrica baixa se deve à limitação das variáveis da base do IBAMA, e não a falhas nos modelos.

### Etapa 3 – Probabilidade (Luís Abdalla)

- **Pedido original:** "O teste de fisher é citado pelo professor? Faça a última alteração necessária para entrega do código.
  **Resposta resumida:** Orientou a fazer apenas a verificação matemática simples exigida no enunciado, sem adicionar testes estatísticos extras.

- **Pedido original:** "Faça uma correção detalhada sobre 'P(Amazônia | multa alta)' e a distinção entre direção causal plausível e escolha generativa do Naive Bayes.
  **Resposta resumida:** Explicou a diferença teórica entre inferência causal e associação amostral, corrigindo uma imprecisão conceitual no relatório.

### Etapa 4 – Aprendizado probabilístico e EM (Hagata Rodrigues e Luís Abdalla)

- **Pedido original (Hagata):** "Me ajuda a fazer o algoritmo EM do zero pra mistura de gaussianas sem dar erro numérico de logaritmo?"
  **Resposta resumida:** Trouxe a lógica de cálculos no espaço logarítmico para manter a estabilidade matemática do código e plotar a convergência corretamente.

- **Pedido original (Luís):** "Me mande a última versão do código, com todos os requisitos do professor, saída limpa e pronto para ser anexado no github.
  **Resposta resumida:** Entregou o código final formatado, limpo e estruturado para ser enviado diretamente ao repositório.

### Etapa 5 – Redes Bayesianas (Maria Penha)

- **Pedido original:** "Como fazer o cálculo da economia de parâmetros?"
  **Resposta resumida:** Explicou que, na conjunta completa, multiplica-se o número de estados de todas as variáveis e subtrai-se 1, o que cresce de forma exponencial. Na rede bayesiana, calcula-se só o espaço das tabelas de probabilidade condicional de cada nó, a partir dos seus pais, $(r-1) \times q$, e somam-se os valores. A subtração do total da rede do valor da conjunta completa dá a economia.

### Etapa 6 – Lógica fuzzy (Adrya Vieira)

- **Pedido original:** "Como construo as funções de pertinência triangulares pro 'risco' e 'efeito' no scikit-fuzzy usando a saída da rede bayesiana?"
  **Resposta resumida:** Mostrou como integrar os limites da biblioteca fuzzy e calibrar a variável de risco utilizando as probabilidades extraídas da etapa anterior.

- **Pedido original:** "Como escrevo a comparação da decisão rígida (corte em 0,5) com o fuzzy, destacando que o fuzzy põe os autos da fronteira na média?"
  **Resposta resumida:** Estruturou a argumentação para o relatório focando na interpretabilidade da transição suave dos autos limítrofes.